

Dự báo tẩy trắng san hô

Tóm tắt nội dung

Báo cáo trình bày một thực nghiệm dự báo và giám sát nguy cơ tẩy trắng san hô quanh Lizard Island, phía bắc Great Barrier Reef, dựa trên dữ liệu NOAA Coral Reef Watch. Bộ dữ liệu gồm chuỗi quan sát ngày từ 2010-01-01 đến 2025-02-08 trên sáu ô lưới không gian, với các đặc trưng nhiệt và cảnh báo gồm SST, SST anomaly, HotSpot, Degree Heating Weeks, Bleaching Alert Area và BAA 7-day maximum composite. Bài toán được thiết kế theo hướng đa nhiệm: dự báo DHW sau 28 ngày và dự báo mức cảnh báo tẩy trắng tương ứng. Các mô hình được so sánh gồm Random Forest, XGBoost, LightGBM, LSTM, GRU, CNN-LSTM, Temporal Fusion Transformer dạng rút gọn và Spatio-Temporal Graph Neural Network. Kết quả cho thấy TFT đạt sai số dự báo DHW thấp nhất, trong khi CNN-LSTM và LSTM có hiệu quả phân loại mức cảnh báo tương đối tốt trong nhóm mô hình sâu. Phân tích kết quả cũng cho thấy mất cân bằng lớp là thách thức chính đối với bài toán cảnh báo sự kiện nghiêm trọng.

1 Giới thiệu

Tẩy trắng san hô là một hiện tượng sinh thái nghiêm trọng xảy ra khi san hô chịu áp lực môi trường, đặc biệt là áp lực nhiệt kéo dài, dẫn đến mất tảo cộng sinh và suy giảm chức năng sinh lý. Đối với các hệ sinh thái rạn, hiện tượng này không chỉ phản ánh biến động ngắn hạn của nhiệt độ mặt biển mà còn thể hiện tác động tích lũy của stress nhiệt theo thời gian. Vì vậy, giám sát và dự báo sớm nguy cơ tẩy trắng có ý nghĩa trực tiếp đối với bảo tồn rạn san hô, quản lý khu bảo tồn biển và lập kế hoạch ứng phó với các đợt nóng biển.

NOAA Coral Reef Watch cung cấp các sản phẩm vệ tinh phục vụ giám sát stress nhiệt san hô ở quy mô toàn cầu, trong đó các biến như HotSpot, Degree Heating Weeks (DHW) và Bleaching Alert Area (BAA) được thiết kế để phản ánh mức độ rủi ro tẩy trắng theo thời gian [1]. Trong thực nghiệm này, các sản phẩm NOAA CRW được sử dụng làm nền tảng dữ liệu chính để xây dựng pipeline dự báo. Mục tiêu của nghiên cứu là đánh giá khả năng của nhiều nhóm mô hình học máy và học sâu trong hai nhiệm vụ liên quan: dự báo cường độ stress nhiệt qua DHW và dự báo mức cảnh báo tẩy trắng sau 28 ngày.

Đóng góp chính của thực nghiệm gồm ba điểm. Thứ nhất, báo cáo xây dựng một quy trình đánh giá có khả năng tái lập, trong đó dữ liệu, đặc trưng, mô hình và chỉ số đánh giá được tổ chức thống nhất. Thứ hai, thực nghiệm so sánh cả mô hình tabular mạnh và mô hình chuỗi thời gian sâu, giúp làm rõ lợi thế tương đối của từng nhóm phương pháp. Thứ ba, báo cáo phân tích sâu đặc điểm dữ liệu, đặc biệt là tính mùa vụ, các năm stress

hiệt cực trị và mất cân bằng lớp cảnh báo, qua đó giải thích các giới hạn thực nghiệm của kết quả dự báo.

2 Ý nghĩa và vai trò của các đặc trưng

2.1 Sea Surface Temperature

Sea Surface Temperature (SST) là nhiệt độ mặt biển tại thời điểm quan sát. Đây là đặc trưng nền tảng vì tẩy trắng san hô thường liên quan trực tiếp đến sự gia tăng nhiệt độ vượt quá điều kiện thích nghi sinh lý của san hô. SST có ý nghĩa mô tả trạng thái nhiệt tức thời, nhưng nếu chỉ dùng SST đơn lẻ thì khó phân biệt được một ngày nóng bình thường theo mùa với một ngày có stress bất thường. Vì vậy SST cần được diễn giải cùng các đặc trưng bất thường và tích lũy.

Trong bộ dữ liệu thực nghiệm, SST trung bình không gian dao động từ 22.51 đến 30.69 độ C, với giá trị trung bình 26.94 độ C. Khoảng dao động này cho thấy khu vực nghiên cứu có mùa vụ nhiệt rõ rệt. Các mô hình cần học được cấu trúc mùa vụ này để tránh xem mọi giá trị SST cao trong mùa hè là tín hiệu cảnh báo mạnh.

2.2 SST anomaly

SST anomaly đo độ lệch của SST so với điều kiện nền hoặc khí hậu học tại cùng khu vực. Đây là đặc trưng có ý nghĩa hơn SST tuyệt đối khi mục tiêu là phát hiện bất thường, vì nó chuẩn hóa một phần tác động của mùa vụ và vị trí địa lý. Hai giá trị SST giống nhau có thể mang ý nghĩa sinh thái khác nhau nếu xuất hiện ở các thời điểm khác nhau trong năm; SST anomaly giúp mô hình nhận biết chênh lệch này.

Về mặt dự báo, SST anomaly thường đóng vai trò như tín hiệu sớm cho sự hình thành stress nhiệt. Khi anomaly dương kéo dài, khả năng HotSpot và DHW tăng lên trong các ngày tiếp theo cũng cao hơn. Do đó, đặc trưng này hỗ trợ cả bài toán hồi quy DHW và bài toán phân loại cảnh báo.

2.3 HotSpot

HotSpot phản ánh mức độ SST vượt ngưỡng nhiệt cực đại theo khí hậu học. Khác với SST anomaly nói chung, HotSpot tập trung trực tiếp vào phần nhiệt vượt ngưỡng có liên quan đến nguy cơ tẩy trắng. Nếu HotSpot nhỏ hoặc âm, điều kiện nhiệt thường chưa đủ mạnh để tích lũy stress tẩy trắng; nếu HotSpot dương và kéo dài, DHW có xu hướng tăng.

Trong pipeline, HotSpot có vai trò kép. Một mặt, nó là biến đầu vào cho mô hình dự báo. Mặt khác, nó tham gia định nghĩa mức cảnh báo tẩy trắng cùng với DHW. Điều này làm cho HotSpot trở thành đặc trưng có liên hệ gần với nhãn phân loại, đồng thời có giá trị diễn giải rõ ràng về cơ chế sinh thái.

2.4 Degree Heating Weeks

DHW là đại lượng tích lũy stress nhiệt trong nhiều tuần. Đặc trưng này quan trọng vì phản ứng tẩy trắng của san hô thường phụ thuộc vào tổng stress kéo dài hơn là nhiệt độ tại một ngày riêng lẻ. DHW càng cao thì nguy cơ tẩy trắng càng lớn; các ngưỡng 4 và 8 DHW thường được sử dụng để phân biệt các mức cảnh báo nghiêm trọng hơn trong hệ thống NOAA CRW.

Trong thực nghiệm, DHW vừa là đặc trưng đầu vào vừa là biến mục tiêu hồi quy sau 28 ngày. Việc đưa DHW quá khứ vào mô hình giúp học quán tính của stress nhiệt: khi DHW đã tích lũy ở mức cao, nó thường không giảm ngay lập tức mà phụ thuộc vào diễn biến nhiệt trong các tuần sau đó. Điều này lý giải vì sao các đặc trưng lag và rolling của DHW có giá trị dự báo cao.

2.5 Bleaching Alert Area và BAA 7-day maximum

Bleaching Alert Area (BAA) là chỉ báo rời rạc phản ánh trạng thái cảnh báo tẩy trắng. BAA giúp chuyển các biến liên tục như HotSpot và DHW thành một thang cảnh báo dễ sử dụng hơn trong quản lý. Trong khi đó, BAA 7-day maximum composite làm mượt một phần dao động ngắn hạn bằng cách ghi nhận mức cảnh báo lớn nhất trong cửa sổ bảy ngày.

Hai đặc trưng này có ý nghĩa vận hành vì người dùng cuối thường quan tâm đến mức cảnh báo hơn là giá trị vật lý đơn lẻ. BAA phản ánh trạng thái tức thời, còn BAA 7-day maximum phản ánh tính bền vững gần đây của cảnh báo. Khi cả hai đều tăng, khả năng sự kiện stress nhiệt đang ổn định hoặc mở rộng thường cao hơn.

2.6 Đặc trưng thời gian, độ trễ và thống kê trượt

Ngoài các biến gốc, pipeline tạo thêm đặc trưng mùa vụ, độ trễ và thống kê trượt. Đặc trưng mùa vụ biểu diễn ngày trong năm bằng hàm sin và cos, giúp mô hình nhận biết chu kỳ năm mà không tạo gián đoạn nhân tạo giữa cuối tháng 12 và đầu tháng 1. Đặc trưng độ trễ cho phép mô hình sử dụng trạng thái quá khứ tại các mốc 1, 3, 7, 14, 28 và 56 ngày. Thống kê trượt như trung bình và cực đại trong 7, 14, 28 và 56 ngày giúp mô hình tóm tắt lịch sử stress nhiệt gần đây.

Về mặt ý nghĩa, nhóm đặc trưng này chuyển dữ liệu quan sát ngày thành biểu diễn có trí nhớ. Đây là bước quan trọng vì tẩy trắng không phải là phản ứng tức thời với một điểm dữ liệu, mà là hệ quả của một chuỗi điều kiện bất lợi kéo dài.

3 Dữ liệu và phân tích dữ liệu


3.1 Phạm vi dữ liệu

Bộ dữ liệu gồm 33,078 quan sát node-level, tương ứng 5,513 ngày trên 6 ô lưới quanh Lizard Island. Chuỗi thời gian bắt đầu từ 2010-01-01 và kết thúc tại 2025-02-08. Khi lấy

trung bình không gian, dữ liệu có 5,513 dòng ngày. Hình 1 minh họa sáu ô lưới được sử dụng trong thực nghiệm.

Phạm vi không gian gồm số lượng ô lưới nhỏ nhưng có lợi cho việc kiểm soát thực nghiệm. Sáu node nằm gần nhau nên các biến nhiệt có xu hướng đồng biến, trong khi khác biệt giữa các node chủ yếu thể hiện ở biên độ cực bộ của SST, HotSpot và DHW. Vì vậy, bộ dữ liệu này phù hợp để đánh giá khả năng học động lực thời gian, nhưng chưa phải điều kiện lý tưởng để kiểm chứng đầy đủ lợi thế của mô hình không gian phức tạp.

Một điểm đáng chú ý là dữ liệu có độ phân giải ngày và chiều dài chuỗi hơn 15 năm. Độ dài này cho phép mô hình quan sát nhiều chu kỳ mùa vụ, nhưng số lần xuất hiện các sự kiện stress nhiệt cao vẫn ít. Do đó, kích thước dữ liệu lớn theo số ngày không đồng nghĩa với số lượng sự kiện cảnh báo lớn; đây là khác biệt quan trọng giữa bài toán dự báo chuỗi thời gian thông thường và bài toán cảnh báo rủi ro sinh thái.



Hình 1: Các ô lưới quan sát quanh khu vực nghiên cứu, tô màu theo giá trị DHW gần nhất trong dữ liệu.

Bảng 1: Tóm tắt phạm vi dữ liệu thực nghiệm.


Thuộc tính	Giá trị
Số ngày quan sát	5,513
Số ô lưới không gian	6
Số quan sát node-level	33,078
Ngày bắt đầu	2010-01-01
Ngày kết thúc	2025-02-08
SST trung bình không gian	26.94 độ C
DHW trung bình không gian	0.763
DHW cực đại trung bình không gian	8.787

3.2 Diễn biến stress nhiệt theo thời gian

Chuỗi DHW trung bình không gian trong Hình 2 thể hiện đặc điểm thưa và theo cụm của các giai đoạn stress nhiệt. Phần lớn thời gian DHW ở mức thấp hoặc bằng không, nhưng một số giai đoạn có tăng mạnh và kéo dài. Điều này cho thấy bài toán dự báo không chỉ là bài toán hồi quy thông thường mà còn là bài toán nhận diện giai đoạn chuyển tiếp từ nền ổn định sang stress nhiệt tích lũy.


Về mặt hình thái chuỗi, DHW có đặc điểm bất đối xứng rõ rệt: giai đoạn tăng thường xảy ra khi HotSpot duy trì dương trong nhiều ngày, còn giai đoạn giảm diễn ra chậm hơn do bản chất tích lũy theo tuần. Điều này làm cho bài toán dự báo 28 ngày phụ thuộc nhiều vào trạng thái trước đó của DHW và xu hướng gần đây của các biến nhiệt. Nói cách khác, giá trị hiện tại của DHW không chỉ là một đặc trưng mô tả mà còn là một biến trạng thái mang thông tin quán tính của hệ thống.

Các đỉnh DHW tập trung chủ yếu trong mùa nóng, nhưng độ lớn giữa các năm khác nhau đáng kể. Sự khác biệt giữa các năm có cùng mùa vụ cho thấy đặc trưng lịch không đủ để dự báo rủi ro; mô hình cần kết hợp mùa vụ với tín hiệu bất thường như SST anomaly và HotSpot. Đây là lý do các đặc trưng nhiệt tuyệt đối, bất thường nhiệt và stress tích lũy được sử dụng đồng thời.



Hình 2: Chuỗi thời gian DHW trung bình không gian trong giai đoạn 2010–2025.

Các năm 2016 và 2017 là hai năm có cực đại DHW cao nhất, lần lượt đạt 8.787 và 8.753. Năm 2024 đạt 6.238, năm 2020 đạt 5.825 và đầu năm 2025 đạt 5.698. Các đỉnh này cho thấy dữ liệu chứa một số sự kiện stress nhiệt mạnh, nhưng số lượng sự kiện nghiêm trọng vẫn ít so với tổng chiều dài chuỗi quan sát.



Hình 3: Cực đại DHW theo năm trong giai đoạn 2010–2025.


Bảng 2: Các năm có cực đại DHW cao nhất.

Năm	Cực đại DHW
2016	8.787
2017	8.753
2024	6.238
2020	5.825
2025	5.698
2021	4.172
2022	4.025
2010	2.075

3.3 Phân bố lớp cảnh báo

Phân bố nhãn cảnh báo trong Hình 4 cho thấy mất cân bằng lớp rất rõ. Trong 33,078 quan sát node-level, No Stress chiếm khoảng 74.08%, Watch chiếm 20.41%, Warning chiếm 3.95%, Alert Level 1 chiếm 1.40% và Alert Level 2 chỉ chiếm 0.17%. Nói cách khác, các lớp có ý nghĩa cảnh báo mạnh chỉ là một phần rất nhỏ của dữ liệu.

Sự phân bố này cho thấy dữ liệu có cấu trúc “nền dài, sự kiện ngắn”. Phần lớn thời gian hệ thống ở trạng thái bình thường hoặc mới bắt đầu theo dõi, trong khi các giai đoạn cảnh báo cao xuất hiện ngắn và không thường xuyên. Đối với học máy, điều này làm tăng nguy cơ mô hình thiên về lớp phổ biến. Đối với ứng dụng thực tế, đây lại chính là phần quan trọng nhất vì các lớp hiếm thường mang ý nghĩa quản lý cao hơn.



Hình 4: Phân bố số lượng quan sát theo mức cảnh báo tẩy trắng.

Bảng 3: Phân bố lớp cảnh báo trong dữ liệu node-level.


Lớp cảnh báo	Số quan sát	Tỷ lệ
No Stress	24,502	74.08%
Watch	6,752	20.41%
Warning	1,307	3.95%
Alert Level 1	462	1.40%
Alert Level 2	55	0.17%

Mất cân bằng này có tác động trực tiếp đến đánh giá mô hình. Một mô hình thiên về dự báo các lớp phổ biến có thể đạt accuracy cao nhưng không hữu ích trong cảnh báo sự kiện nghiêm trọng. Vì vậy, macro-F1, balanced accuracy và event recall cần được xem cùng với accuracy.

Ngoài ra, lớp Warning có vai trò chuyển tiếp giữa Watch và Alert Level 1. Nếu mô hình nhầm Warning thành Watch, hệ thống có thể đánh giá thấp rủi ro đang hình thành; nếu nhầm Alert Level 1 thành Warning, hệ thống có thể bỏ lỡ ngưỡng cảnh báo quan trọng. Do đó, lỗi phân loại gần ngưỡng cảnh báo cần được diễn giải cẩn trọng hơn lỗi giữa các lớp nền.

3.4 Tương quan giữa các đặc trưng

Ma trận tương quan trong Hình 5 cho thấy các biến nhiệt có liên hệ mạnh. SST, SST anomaly và HotSpot thể hiện trạng thái nhiệt tức thời hoặc bất thường, trong khi DHW phản ánh tích lũy stress nhiệt. Do DHW được hình thành từ stress kéo dài, nó có quan hệ chặt với các biến nhiệt trước đó nhưng không đồng nhất hoàn toàn với SST tại một ngày.



Hình 5: Ma trận tương quan giữa các đặc trưng đầu vào.

Ý nghĩa thực nghiệm của tương quan cao là hai mặt. Ở mặt tích cực, mô hình có nhiều tín hiệu nhất quán để nhận diện stress nhiệt. Ở mặt hạn chế, một số đặc trưng có thể mang thông tin chồng lặp, làm tăng nguy cơ mô hình học các quan hệ gần định nghĩa thay vì các dấu hiệu dự báo sớm. Vì vậy, đánh giá trên tập kiểm tra theo thời gian là cần thiết để xem mô hình có tổng quát hóa qua các năm khác nhau hay không.

Quan sát tương quan cũng giúp giải thích vì sao các mô hình tabular có thể cạnh tranh với mô hình sâu. Khi các biến gốc và các đặc trưng trễ đã mang thông tin mạnh về trạng thái nhiệt, mô hình cây boosting có thể học các ngưỡng phi tuyến khá hiệu quả. Ngược lại, lợi thế của mô hình chuỗi thời gian chỉ thể hiện rõ khi cần học hình dạng động học của chuỗi, ví dụ tốc độ tăng, độ bền của HotSpot hoặc độ dài giai đoạn tích lũy DHW.

4 Mô hình thực nghiệm

4.1 Mô hình tabular

Random Forest được dùng như baseline mạnh cho dữ liệu dạng bảng vì có khả năng học quan hệ phi tuyến và tương tác biến mà không đòi hỏi giả định tuyến tính [2]. Trong thực nghiệm, Random Forest sử dụng các đặc trưng gốc, đặc trưng mùa vụ, độ trễ và thống kê trượt.

XGBoost là mô hình gradient boosting trên cây quyết định, thường đạt hiệu quả cao trên dữ liệu tabular nhờ tối ưu tuần tự các cây yếu và cơ chế regularization [3]. LightGBM cũng thuộc nhóm gradient boosting, nhưng được thiết kế để huấn luyện hiệu quả với chiến lược phát triển cây theo lá và các kỹ thuật giảm chi phí tính toán [4]. Hai mô hình này đóng vai trò baseline cạnh tranh cao cho các mô hình học sâu.

4.2 Mô hình chuỗi thời gian sâu

LSTM được sử dụng để học phụ thuộc dài hạn trong chuỗi thời gian, khắc phục một phần vấn đề suy giảm gradient của mạng hồi tiếp truyền thống [5]. GRU là biến thể gọn hơn của kiến trúc hồi tiếp có cổng, thường có ít tham số hơn LSTM nhưng vẫn có khả năng lưu giữ thông tin quá khứ [6].

CNN-LSTM kết hợp convolution một chiều và LSTM. Khối convolution giúp nhận diện các mẫu ngắn hạn trong cửa sổ đầu vào, chẳng hạn sự tăng nhanh của HotSpot hoặc SST anomaly; LSTM sau đó học quan hệ dài hơn giữa các mẫu này và mục tiêu dự báo.

Temporal Fusion Transformer dạng rút gọn sử dụng cơ chế attention để học trọng số theo thời gian, phù hợp với bài toán chuỗi nơi không phải mọi ngày trong cửa sổ 90 ngày đều có vai trò như nhau [7]. Trong ngữ cảnh stress nhiệt, attention có thể giúp mô hình tập trung vào các đoạn tăng nhiệt liên tục trước khi DHW đạt đỉnh.

4.3 Mô hình không gian–thời gian

ST-GNN biểu diễn mỗi ô lưới như một node trong đồ thị và dùng khoảng cách địa lý để xác định mức liên hệ giữa các node. Ý tưởng này kế thừa tinh thần của graph neural networks, trong đó thông tin của một node được cập nhật từ các node lân cận [8]. Với dữ liệu raster san hô, mô hình không gian–thời gian có ý nghĩa khi stress nhiệt có cấu trúc lan truyền hoặc đồng biến theo vị trí.

5 Thiết lập đánh giá

Bài toán được đánh giá theo hai hướng. Với dự báo DHW, các chỉ số gồm MAE, RMSE và R^2 . MAE cho biết sai số tuyệt đối trung bình, RMSE nhạy hơn với sai số lớn, còn R^2 phản ánh tỷ lệ phương sai mục tiêu được mô hình giải thích. Với dự báo mức cảnh báo, các chỉ số gồm accuracy, balanced accuracy, macro-F1 và weighted-F1. Do dữ liệu mất cân bằng lớp, macro-F1 và balanced accuracy có ý nghĩa hơn accuracy khi đánh giá khả năng nhận diện các lớp hiếm.

Ngoài ra, báo cáo sử dụng event precision, event recall và event-F1 cho nhóm sự kiện từ Alert Level 1 trở lên. Đây là nhóm có ý nghĩa vận hành vì phản ánh tình huống cần cảnh báo sớm. Trong bối cảnh bảo tồn, event recall thấp nghĩa là hệ thống bỏ sót nhiều sự kiện nguy cơ cao, còn event precision thấp nghĩa là hệ thống tạo nhiều cảnh báo sai. Tùy mục tiêu sử dụng, hai đại lượng này cần được cân bằng khác nhau.

Tập kiểm tra được lấy sau năm 2022, trong khi tập huấn luyện và validation nằm ở các

giai đoạn trước đó. Cách chia này làm cho đánh giá gần hơn với tình huống vận hành thực tế, nơi mô hình phải dự báo các năm tương lai từ dữ liệu lịch sử.

6 Kết quả, đánh giá và biện luận

Bảng 4: So sánh kết quả hồi quy và phân loại.

Mô hình	Nhóm	MAE	RMSE	R^2	Accuracy	Bal. Acc.
TFT	Deep	0.436	0.805	0.799	0.819	0.423
CNN-LSTM	Deep	0.487	0.905	0.746	0.822	0.436
XGBoost	Tabular	0.449	0.945	0.724	0.808	0.415
LSTM	Deep	0.563	0.994	0.694	0.825	0.438
Random Forest	Tabular	0.424	0.999	0.692	0.786	0.396
LightGBM	Tabular	0.511	1.005	0.688	0.805	0.414
ST-GNN	Deep	0.607	1.076	0.642	0.757	0.367
GRU	Deep	0.688	1.117	0.614	0.804	0.409


Nhận xét: Theo chỉ số hồi quy DHW, TFT đạt hiệu quả tốt nhất với $RMSE = 0.805$ và $R^2 = 0.799$, cho thấy mô hình attention khai thác hiệu quả cấu trúc thời gian trong dự báo stress nhiệt. Random Forest đạt MAE thấp nhất (0.424) với độ ổn định sai số trung bình, nhưng RMSE cao hơn, gợi ý mô hình này kém hơn ở các sai số lớn. LSTM đạt accuracy cao nhất (0.825) với balanced accuracy tốt nhất (0.438), cho thấy hiệu quả tương đối đồng đều giữa các lớp. Khoảng cách giữa các mô hình theo RMSE không lớn (0.805–1.117), nhưng khác biệt theo R^2 rõ rệt hơn (0.614–0.799), nhấn mạnh vai trò mô hình attention.

Bảng 5: So sánh chỉ số phân loại chi tiết và phát hiện sự kiện cảnh báo.

Mô hình	Macro-F1	Weighted-F1	Event Prec.	Event Rec.	Event F1
TFT	0.406	0.778	0.000	0.000	0.000
CNN-LSTM	0.427	0.786	0.200	0.045	0.074
XGBoost	0.323	0.773	0.044	0.029	0.035
LSTM	0.425	0.797	0.048	0.045	0.047
Random Forest	0.309	0.748	0.098	0.065	0.078
LightGBM	0.321	0.774	0.101	0.058	0.073
ST-GNN	0.355	0.704	0.000	0.000	0.000
GRU	0.394	0.761	0.000	0.000	0.000


Nhận xét: CNN-LSTM đạt macro-F1 cao nhất (0.427) với weighted-F1 tốt nhất (0.786), cho thấy cân bằng tốt giữa các lớp và ổn định với trọng số lớp. Trong phát hiện sự kiện cảnh báo cao, Random Forest vượt trội với event recall 6.5% và event F1 7.8%, gợi ý mô hình tabular nhạy hơn với các mẫu hiếm. LightGBM đạt event precision cao nhất (10.1%). Ngược lại, TFT, ST-GNN và GRU không phát hiện sự kiện cảnh báo (event metrics = 0), dù TFT xuất sắc về hồi quy. Khoảng cách giữa macro-F1 (0.309–0.427) và

event metrics (0–0.101) rất lớn, minh chứng tác động mất cân bằng lớp: các mô hình tốt ở phân loại chung nhưng bỏ sót sự kiện hiếm có ý nghĩa quản lý cao.



Hình 6: So sánh mô hình theo RMSE của dự báo DHW.

Nhóm mô hình tabular vẫn có tính cạnh tranh rõ rệt. XGBoost đạt $RMSE = 0.945$, tốt hơn LSTM, Random Forest và LightGBM. Điều này cho thấy các đặc trưng lag và rolling đã mã hóa được nhiều thông tin thời gian quan trọng, đủ để mô hình cây boosting khai thác hiệu quả mà không cần kiến trúc chuỗi phức tạp. Random Forest có MAE thấp nhất trong bảng nhưng RMSE cao hơn TFT và XGBoost, cho thấy mô hình này ổn định với sai số trung bình nhưng kém hơn ở các trường hợp sai số lớn.




Hình 7: So sánh mô hình theo macro-F1 của dự báo mức cảnh báo.

Với bài toán phân loại, accuracy của nhiều mô hình đạt trên 0.80, nhưng macro-F1 chỉ nằm trong khoảng 0.309 đến 0.427. Khoảng cách lớn giữa accuracy và macro-F1 xác nhận tác động của mất cân bằng lớp. Nếu chỉ nhìn accuracy, LSTM có thể được xem là mô hình tốt nhất vì đạt 0.825; tuy nhiên CNN-LSTM lại có macro-F1 cao hơn, phản ánh cân bằng tốt hơn giữa các lớp. Vì vậy, đối với bài toán cảnh báo, lựa chọn mô hình không nên dựa đơn thuần vào accuracy.

Khi xem riêng các sự kiện từ Alert Level 1 trở lên, khả năng phát hiện vẫn còn hạn chế. Random Forest có khả năng bắt được nhiều sự kiện cảnh báo hơn một số mô hình khác,

trong khi TFT dù dự báo DHW tốt nhất lại chưa thể hiện tốt ở khía cạnh phát hiện sự kiện hiếm trong cấu hình hiện tại. Kết quả này cho thấy tối ưu hồi quy DHW không tự động dẫn đến phát hiện tốt cảnh báo cao. Một mô hình có sai số DHW thấp vẫn có thể dự báo thấp hơn ngưỡng cảnh báo tại các thời điểm hiếm, dẫn đến bỏ sót sự kiện.



Hình 8: Đường cong loss huấn luyện và validation của mô hình TFT.

Đường cong huấn luyện của TFT cho thấy validation loss giảm trong giai đoạn đầu và được kiểm soát bằng early stopping. Điều này cho thấy quy trình huấn luyện không chỉ chọn epoch cuối mà chọn checkpoint có validation loss tốt nhất. Tuy nhiên, đánh giá theo event recall chỉ ra rằng cần bổ sung mục tiêu tối ưu hướng sự kiện, chẳng hạn tăng trọng số lớp hiếm, dùng focal loss, oversampling theo giai đoạn stress nhiệt, hoặc điều chỉnh ngưỡng cảnh báo sau huấn luyện.

ST-GNN chưa thể hiện ưu thế trong thực nghiệm hiện tại. Nguyên nhân hợp lý là đồ thị không gian chỉ có sáu node và phạm vi địa lý hẹp. Với dữ liệu nhỏ như vậy, thông tin không gian bổ sung không đủ phong phú để mô hình đồ thị vượt qua các mô hình chuỗi hoặc mô hình tabular. Nếu phạm vi quan sát được mở rộng sang nhiều cụm rạn hơn, ST-GNN có thể có điều kiện phát huy vai trò tốt hơn.

Tổng hợp lại, kết quả thực nghiệm cho thấy bài toán dự báo DHW khả thi với dữ liệu NOAA CRW hiện có, nhưng bài toán cảnh báo sự kiện nghiêm trọng vẫn khó hơn đáng kể. Đối với mục tiêu giám sát vận hành, mô hình cần được đánh giá bằng các chỉ số hướng sự kiện thay vì chỉ RMSE hoặc accuracy.

7 Kết luận

Báo cáo đã trình bày một thực nghiệm dự báo tẩy trắng san hô quanh Lizard Island dựa trên dữ liệu NOAA Coral Reef Watch. Các đặc trưng SST, SST anomaly, HotSpot, DHW, BAA và BAA 7-day maximum composite có ý nghĩa bổ sung cho nhau: SST mô tả trạng thái nhiệt tức thời, SST anomaly và HotSpot phản ánh bất thường nhiệt, DHW biểu diễn stress tích lũy, còn BAA chuyển thông tin vật lý thành mức cảnh báo vận hành.

Trong các mô hình được so sánh, TFT đạt sai số DHW thấp nhất, CNN-LSTM đạt macro-

F1 cao nhất, còn các mô hình tabular như XGBoost, Random Forest và LightGBM vẫn giữ vai trò baseline mạnh. Phân tích đánh giá cho thấy mất cân bằng lớp là thách thức chính làm giảm khả năng phát hiện Alert Level 1 trở lên. Do đó, hướng cải thiện quan trọng tiếp theo là tối ưu mô hình theo mục tiêu cảnh báo sự kiện, thay vì chỉ tối ưu sai số trung bình của DHW.

Tài liệu

- [1] NOAA Coral Reef Watch. (2026) NOAA Coral Reef Watch Daily 5 km Satellite Coral Bleaching Heat Stress Products. Accessed: Jun. 21, 2026. [Online]. Available: https://coastwatch.pfeg.noaa.gov/erddap/info/NOAA_DHW/index.html
- [2] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [3] T. Chen and C. Guestrin, “XGBoost: a scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining*, 2016, pp. 785–794.
- [4] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, “LightGBM: a highly efficient gradient boosting decision tree,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 3146–3154.
- [5] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [6] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, “Learning phrase representations using RNN encoder–decoder for statistical machine translation,” in *Proc. 2014 Conf. Empirical Methods Natural Language Processing*, 2014, pp. 1724–1734.
- [7] B. Lim, S. O. Arik, N. Loeff, and T. Pfister, “Temporal fusion transformers for interpretable multi-horizon time series forecasting,” *International Journal of Forecasting*, vol. 37, no. 4, pp. 1748–1764, 2021.
- [8] T. N. Kipf and M. Welling, “Semi-supervised classification with graph convolutional networks,” in *Proc. Int. Conf. Learning Representations*, 2017. [Online]. Available: <https://arxiv.org/abs/1609.02907>